



Estimación de los niveles de obesidad basado en hábitos alimenticios y actividad física en individuos de Colombia, Perú y México, utilizando modelos de aprendizaje supervisado

Diplomado Introducción Analítica a la Ciencia de Datos

27 Junio 2026

Cruz Cruz Araceli Yolanda González Padilla Alberto

Loyola Alarcón Karla Valeria López López José Fortino

Sánchez Montalvo Luis Antonio

Facultad de Ciencias, UNAM.

Resumen

La obesidad constituye uno de los principales problemas de salud pública a nivel mundial debido a su asociación con enfermedades cardiovasculares, diabetes y otras patologías crónicas. El objetivo de este proyecto fue desarrollar un modelo de clasificación capaz de predecir el nivel de obesidad de una persona a partir de características demográficas, hábitos alimenticios y condiciones físicas.

Se utilizó el conjunto de datos *Estimation of Obesity Levels Based on Eating Habits and Physical Condition* proveniente del repositorio UCI Machine Learning Repository. Tras realizar un análisis exploratorio, preprocesamiento de variables y comparación de diversos algoritmos de aprendizaje supervisado, se identificó a XGBoost como el modelo con mejor desempeño.

Los resultados muestran que variables como el peso corporal, la altura y los antecedentes familiares tienen una influencia significativa en la clasificación de los niveles de obesidad. Adicionalmente, se aplicaron técnicas de interpretabilidad mediante SHAP para comprender la contribución de cada variable en las predicciones.

Palabras clave: *Obesidad, XGBoost, Hábitos, Salud, Aprendizaje supervisado, SHAP*

1. Introducción

La obesidad representa uno de los problemas de salud pública más urgentes del siglo XXI. Según la Organización Mundial de la Salud, desde 1990 la prevalencia mundial de obesidad se ha más que duplicado, y América Latina no es la excepción: México, Colombia y Perú concentran millones de casos vinculados a estilos de vida sedentarios, hábitos alimenticios deficientes y factores socioeconómicos. La detección temprana y la clasificación precisa del nivel de riesgo de un individuo constituyen pasos esenciales para orientar intervenciones clínicas y políticas de salud preventiva.

La obesidad representa una condición multifactorial asociada a hábitos alimenticios, actividad física, factores genéticos y estilos de vida. La disponibilidad de información relacionada con estos factores permite utilizar técnicas de aprendizaje automático para identificar patrones y construir modelos predictivos que apoyen la toma de decisiones en salud pública.

El presente trabajo desarrolla un modelo de clasificación multiclase para estimar el nivel de obesidad de un individuo a partir de variables relacionadas con su comportamiento alimenticio y condición física.

2. Objetivos

2.1. Objetivo General

Desarrollar un modelo de Machine Learning capaz de clasificar el nivel de obesidad de una persona utilizando variables demográficas, alimenticias y físicas.

2.2. Objetivos Específicos

- **Explorar y preprocesar** el conjunto de datos, identificando distribuciones, valores atípicos, relaciones entre variables y requerimientos de transformación.
- **Entrenar y comparar** una familia representativa de modelos supervisados: modelos lineales con regularización (Lasso / Ridge), ensambles basados en árboles (Random Forest, AdaBoost, XGBoost) y redes neuronales (MLP).
- **Evaluar e interpretar** los modelos no solo en términos de métricas de rendimiento, sino en cuanto a su explicabilidad: importancia de variables, coeficientes regularizados y comportamiento diferencial entre algoritmos.

3. Descripción del Dataset

El conjunto de datos fue obtenido de repositorio UCI Machine Learning Repository (Dataset ID 544). El repositorio consolida 2111 registros poblacionales estructurados en 17 atributos.

3.1. Variable Objetivo

La variable objetivo (**NObesidad**) representa la categoría de estado nutricional del individuo y está compuesta por siete niveles, definidos conforme a los criterios de clasificación de la Organización Mundial de la Salud (OMS) y otras referencias internacionales. En el caso de personas de 18 años o más, dichas categorías se determinan a partir de los siguientes rangos del Índice de Masa Corporal (IMC):

- Insufficient Weight: IMC menor a 18.5
- Normal Weight: IMC entre 18.5 y 24.9.
- Overweight Level I & II: IMC entre 25.0 y 29.9.
- Obesity Type I: IMC entre 30.0 y 34.9.
- Obesity Type II: IMC entre 35.0 y 39.9.
- Obesity Type III: IMC de 40.0 o superior.

Es importante notar que algunos estudios, utilizan etiquetas más granulares para el análisis de datos, subdividiendo el sobrepeso en Sobrepeso Nivel I y Sobrepeso Nivel II. Aunque el IMC es la herramienta estándar, las fuentes subrayan que existen otras mediciones, como el perímetro de la cintura, que ayudan a diagnosticar la obesidad.

3.2. Variables Explicativas

Las variables predictoras consideradas en el análisis abarcan dimensiones biométricas, genéticas y de comportamiento, proporcionando una descripción integral de los factores potencialmente asociados con los niveles de obesidad. Estas son las siguientes:

- Age (*Edad*).
- Gender (*Género*).
- Weight (*Peso*).
- Height (*Altura*).

- FCVC (*Frecuencia de consumo de vegetales*).
- FAVC (*Frecuencia de consumo de alimentos hipercalóricos*).
- NCP (*Número de comidas principales*).
- CH20 (*Consumo diario de agua*).
- FAF (*Actividad física*).
- TUE (*Uso de dispositivos electrónicos*).
- CALC (*Consumo de alcohol*).
- family_history_with_overweight (*Antecedentes familiares de sobrepeso*).
- SMOKE (*Consumo de tabaco*).
- CAEC (*Consumo alimentos entre comidas principales*).
- SCC (*Monitoreo de consumo de calorías*).
- MTRANS (*Método de transporte*).

4. Análisis Exploratorio de Datos

4.1. Calidad de Datos

El análisis exploratorio reveló una buena calidad en el conjunto de datos. Los principales hallazgos se resumen a continuación:

- **Ausencia de valores faltantes:** El conjunto de datos no presenta valores nulos (0 % de datos faltantes), por lo que no fue necesario aplicar técnicas de imputación para completar la información.
- **Presencia mínima de registros duplicados:** Se identificaron únicamente 24 registros duplicados. Dado que esta cantidad representa una proporción reducida del total de registros, su impacto sobre los resultados es limitado y no compromete la consistencia de los datos.
- **Distribución balanceada de la variable objetivo:** Presenta una distribución relativamente equilibrada entre sus categorías. De acuerdo con la documentación del conjunto de datos, aproximadamente el 23 % de las observaciones proviene de encuestas aplicadas directamente a individuos, mientras que el 77 % restante fue generado mediante la técnica *Synthetic Minority Over-sampling Technique* (SMOTE), implementada a través del software Weka. Este procedimiento fue descrito por Mendoza Palechor y De la Hoz Manotas (2019) en el artículo titulado *Dataset for Estimation of Obesity Levels Based on Eating Habits and Physical Condition in Individuals from Colombia, Peru and Mexico*.

Para ilustrar la distribución de la variable objetivo, se presenta la siguiente figura:




Figura 1: Impacto del balanceo SMOTE sobre la distribución de clases.

4.2. Variables Numéricas

Las principales variables numéricas analizadas fueron:

- Age
- Height
- Weight

Se identificó una correlación lineal positiva moderada entre el peso y la estatura, lo que sugiere que, en general, a mayor estatura corresponde un mayor peso. Esta relación puede observarse en la figura 2.




Figura 2: Matriz de correlación

A continuación, se presentan análisis complementarios de las variables numéricas consideradas.




Figura 3: Distribución de Variables Numéricas




Figura 4: Identificación de Valores Atípicos

A partir de las Figuras 3 y 4 se identifican los siguientes hallazgos:

- La variable **Age** presenta valores comprendidos entre 14 y 61 años, con una media de 24.35 años y una mediana de 22.85 años.
- La variable **Weight** registra valores entre 39 y 173 kg, con una media de 87 kg y una mediana de 83 kg.
- La variable **Height** presenta valores comprendidos entre 1.45 m y 1.98 m. Tanto la media como la mediana se sitúan alrededor de 1.70 m.
- Entre las variables **Weight** y **Height** se observa una correlación lineal positiva moderada ($r = 0.46$), lo que sugiere una tendencia al incremento del peso conforme aumenta la estatura.

En relación con la forma de las distribuciones, se observan los siguientes comportamientos:

- La variable **Age** presenta una distribución asimétrica con sesgo positivo. Aproximadamente el 1 % de los registros corresponde a individuos con edades iguales o superiores a 44 años.
- La variable **Height** muestra una distribución aproximadamente simétrica y cercana a una distribución normal, concentrada alrededor de los 1.70 m.
- La variable **Weight** presenta una mayor dispersión y evidencia un comportamiento multimodal, lo que sugiere la existencia de distintos grupos de individuos con características corporales diferenciadas. Este resultado es consistente con la presencia de múltiples categorías de obesidad en la variable objetivo.
- Los diagramas de caja permiten identificar valores atípicos principalmente en las variables **Age** y **Weight**, mientras que la variable **Height** presenta una menor cantidad de observaciones extremas.

4.3. Variables Categóricas

La distribución de las variables categóricas se presenta en el Cuadro 1. A partir de esta información, es posible identificar los patrones más relevantes de la muestra y caracterizar sus principales hábitos y condiciones.

A partir de la distribución anterior, se identifica lo siguiente:

- La muestra presenta una distribución equilibrada por género.
- La mayoría de los individuos reporta antecedentes familiares de sobrepeso, lo que sugiere una posible influencia hereditaria en la variable objetivo.
- Una proporción elevada de la muestra consume frecuentemente alimentos altos en calorías.
- Más del 80 % de los individuos indica consumir alimentos entre comidas al menos de forma ocasional.
- El consumo de verduras se concentra principalmente en las categorías “Sometimes” y “Always”, mientras que una proporción reducida reporta no consumirlas.
- La mayoría de los individuos realiza más de tres comidas principales al día.

Tabla 1: Distribución de Variables Categóricas

Variable	Categoría	Porcentaje (%)
Gender	Female	49.6
	Male	50.4
family_history_with_overweight	yes	82.5
	no	17.5
frequently_consume_high_calorie_food	no	11.6
	yes	88.4
freq_consume_vegetables	Never	4.9
	Sometimes	47.6
	Always	47.5
num_main_meals	Between 1 and 2	14.2
	Three	8.4
	More than three	70.2
consume_food_between_meals	Sometimes	84.4
	Frequently	11.3
	Always	2.5
	no	1.8
smoke	no	97.9
	yes	2.1
consume_water	Less than a liter	22.9
	Between 1 and 2 L	53.0
	More than 2 L	24.1
monitor_calorie_intake	no	95.4
	yes	4.6
freq_physical_activity	Never	34.2
	1 or 2 days	36.4
	2 or 4 days	23.7
	4 or 5 days	5.7
time_using_electronic_devices	0-2 hours	44.7
	3-5 hours	43.7
	More than 5 hours	11.6
freq_consume_alcohol	no	30.5
	Sometimes	66.1
	Frequently	3.4
	Always	0.0
type_transportation	Public Transportation	74.7
	Walking	2.6
	Automobile	21.8
	Motorbike	0.5
	Bike	0.3

- El consumo de tabaco es bajo en la muestra, ya que casi la totalidad de los registros corresponde a la categoría “no”.
- El consumo de agua se concentra principalmente entre 1 y 2 litros diarios.
- Una proporción muy alta de la muestra no realiza monitoreo del consumo calórico.
- La actividad física se distribuye principalmente entre quienes nunca la realizan y quienes la practican uno o dos días por semana.
- El uso de dispositivos electrónicos se concentra entre 0 y 5 horas diarias.
- El consumo de alcohol ocurre principalmente de forma ocasional, mientras que el consumo frecuente o constante es reducido.
- El medio de transporte más utilizado es el transporte público, seguido por el automóvil.

4.4. Otros hallazgos

Este análisis incluyó el estudio de las variables categóricas con el propósito de identificar posibles desbalances en la muestra, así como el análisis de las variables numéricas en relación con la variable objetivo mediante diagramas de caja. El objetivo principal de estas visualizaciones fue evaluar la capacidad discriminante de características como la edad, el peso y determinados hábitos de consumo frente a los distintos niveles de obesidad.

Por motivos de espacio y para mantener la concisión del presente reporte, no se incluyen en este documento las visualizaciones detalladas de las distribuciones, los gráficos de comportamiento ni los cruces específicos por género y hábitos sociodemográficos. No obstante, toda la evidencia gráfica y el código correspondiente pueden consultarse en el notebook del proyecto.

4.4.1. Conclusiones sobre las variables categóricas por nivel de la variable objetivo

- Aproximadamente 4 de cada 10 individuos presentan algún tipo de obesidad y, en su mayoría, reportan antecedentes familiares de sobrepeso.
- Entre los individuos con obesidad, se observa una alta frecuencia de consumo de alimentos con elevado contenido calórico, ingesta de alimentos entre comidas y ausencia de monitoreo del consumo calórico.
- El 15.5 % de los entrevistados registra obesidad tipo III. En este grupo, la totalidad corresponde a mujeres. Además, 6 de cada 10 no realizan actividad física, presentan más de tres comidas principales al día, 46 % consume más de 2 litros de agua diariamente y casi 7 de cada 10 utiliza dispositivos electrónicos entre 3 y 5 horas al día. Asimismo, todas las personas de este grupo reportan consumo ocasional de alcohol.
- Las personas con obesidad tipo III consumen verduras en todas sus comidas en el 100 % de los casos. De igual forma, este grupo concentra el porcentaje más alto de consumo diario superior a dos litros de agua.
- El 14 % de los casos clasificados con obesidad tipo II corresponde al género masculino.
- Entre los individuos identificados con peso insuficiente (*Insufficient Weight*), el 63 % corresponde al género femenino.

4.4.2. Conclusiones sobre las variables numéricas por nivel de obesidad

En relación con las variables numéricas, se obtuvieron los siguientes resultados:

- Los individuos clasificados con obesidad tipo III (*Obesity_Type_III*) presentan un rango de edad reducido, comprendido entre los 18 y 26 años.
- La variable *Weight* constituye un diferenciador claro entre los distintos niveles de la variable objetivo, tal como se esperaba.

- Los diagramas de caja muestran que el peso presenta una relación directa con el nivel de obesidad, observándose un incremento progresivo de las medianas conforme aumenta la categoría. En contraste, la edad y la actividad física exhiben un mayor solapamiento entre grupos, lo que sugiere una menor capacidad discriminante cuando se analizan de forma individual. Aunque existen diferencias entre categorías, estas no son tan marcadas como las observadas en la variable peso, por lo que se espera que esta última tenga mayor importancia en los modelos de clasificación.

5. Preparación de Datos

El proceso de preparación de datos incluyó las siguientes etapas:

- **Codificación de variables binarias y categóricas:**
 - La variable género y las variables con respuesta *sí/no* se mapearon a valores de 0 y 1.
 - Para la variable *Tipo de Transporte*, que presenta múltiples categorías sin un orden jerárquico natural, se aplicó una codificación *One-Hot Encoding*, eliminando la primera categoría de referencia para evitar multicolinealidad.
- **Recodificación de variables ordinales e imputación:**
 - Las variables que describen frecuencias de hábitos alimenticios y de estilo de vida, como el consumo de agua, verduras, alcohol y el tiempo de uso de dispositivos electrónicos, se integraron en un *pipeline*.
 - En primer lugar, se imputaron los valores ausentes mediante la moda (*SimpleImputer* con la categoría más frecuente).
 - Posteriormente, se aplicó un codificador ordinal respetando la progresión natural de las categorías, desde niveles bajos hasta niveles altos.
- **Estandarización de variables numéricas:**
 - Las variables *Age*, *Height* y *Weight* fueron estandarizadas mediante *StandardScaler*.

6. Metodología de Modelado y Optimización de Hiperparámetros

Para la estimación de los niveles de obesidad se diseñó un flujo de trabajo robusto y reproducible. El proceso se estructuró mediante *Pipelines* secuenciales para garantizar el aislamiento de los datos y prevenir la fuga de información (*data leakage*) durante las etapas de preprocesamiento, validación y evaluación.

6.1. Estrategia del Modelo Base (Baseline)

Con el objetivo de establecer un umbral mínimo de rendimiento estadístico y justificar la complejidad de los algoritmos avanzados, se implementó un **Modelo Base** consistente en una Regresión Logística con sus hiperparámetros por defecto (*solver = 'lbfgs', max_iter = 5000*). Este modelo actúa como la cota inferior de rendimiento lineal contra la cual se contrastan las familias de modelos de mayor complejidad algorítmica.

6.2. Espacio de Modelos Candidatos

Se evaluaron ocho modelos adicionales pertenecientes a cinco familias distintas de aprendizaje supervisado: modelos lineales penalizados, métodos basados en kernels, algoritmos probabilísticos, ensambles de árboles de decisión y redes neuronales artificiales.

Para cada algoritmo, se definió un espacio de búsqueda exhaustivo de hiperparámetros (Grid Search), detallado en la Tabla 2.

Tabla 2: Espacio de búsqueda de hiperparámetros por familia de modelos.

Modelo	Familia Algorítmica	Espacio de Hiperparámetros Evaluado
<code>modelo_base_LR</code>	Lineal (Baseline)	Parámetros por defecto (Sin optimización)
<code>lr_Ridge_L2</code>	Lineal	Penalización L2 ($C \in [10^{-2}, 10^2]$, 10 valores equidistantes)
<code>lr_Lasso_L1</code>	Lineal	Penalización L1 ($C \in [10^{-3}, 10^1]$, 10 valores equidistantes)
<code>svc</code>	Kernel	Kernel: [linear, rbf, poly, sigmoid]; $C \in [10^{-3}, 10^3]$; $\gamma \in [10^{-2}, 10^1]$
<code>Naive_Bayes</code>	Probabilístico	<code>var_smoothing</code> $\in [10^{-12}, 10^{-1}]$, 15 valores equidistantes
<code>random_forest</code>	Ensamble	<code>n_estimators</code> $\in [150, 350)$ con pasos de 30; <code>max_depth</code> $\in [5, 30)$ con pasos de 5
<code>AdaBoost</code>	Ensamble	Est.: <code>DecisionTreeClassifier(max_depth = 1)</code> ; <code>n_estimators</code> $\in [150, 350)$ paso 30; <code>learning_rate</code> $\in [0.01, 10]$
<code>XGBoost</code>	Ensamble	Objetivo: <code>multi:softprob</code> ; <code>n_estimators</code> $\in [150, 350)$ paso 30; <code>learning_rate</code> $\in [0.01, 10]$; <code>max_depth</code> $\in \{1, 3, 5, 7, 9\}$
<code>MLP</code>	Red Neuronal	Capas ocultas: [(100,), (100, 50), (128, 64, 32)]; Activación: [relu, tanh]; $\alpha \in [10^{-4}, 10^{-2}]$; <code>lr_init</code> $\in \{0.001, 0.01\}$

6.3. Estrategia de Optimización y Protocolo de Validación

La búsqueda de la combinación óptima de hiperparámetros se realizó mediante el algoritmo *GridSearchCV*. Para asegurar que el modelo sea capaz de generalizar a datos no vistos previamente, prevenir la fuga de información y mitigar el sobreajuste (*overfitting*), se realizó lo siguiente:

1. **Partición Estratificada (Hold-out):** Previo a cualquier fase de modelado, el conjunto de covariables (X) y la variable objetivo (y) se dividieron en una proporción del 80 % para el entrenamiento (X_{train}, y_{train}) y un 20 % para la prueba (X_{test}, y_{test}). Se aplicó un algoritmo de estratificación basado en la variable objetivo para garantizar que la prevalencia original de cada nivel de obesidad se mantuviera idéntica en ambos subconjuntos.
2. **Validación Cruzada (Cross-Validation):** Durante la fase de optimización, se utilizó K-Folds con 5 particiones ($CV = 5$) estrictamente sobre el conjunto de entrenamiento de forma interna, asegurando que el modelo se evaluara en múltiples submuestras antes de seleccionar sus parámetros finales.
3. **Métrica de Optimización:** La métrica *Accuracy* (aciertos globales) fue la utilizada para seleccionar la mejor configuración de hiperparámetros. Sin embargo, con el fin de asegurar la robustez diagnóstica requerida en un problema de salud pública de naturaleza multiclase, el análisis del rendimiento se expandió para incluir las métricas macro de *F1-Score*, *Precision* y *Recall*.
4. **Evaluación de Generalización:** Una vez seleccionado el mejor conjunto de parámetros para cada tipo de modelo mediante la validación cruzada, el rendimiento definitivo y comparativo se extrajo al realizar inferencias sobre el 20 % de datos de prueba (X_{test}), simulando así el despliegue del sistema en un entorno clínico real con pacientes no observados previamente.

7. Resultados

Una vez realizado el proceso de modelado y optimización de hiperparámetros, se obtuvieron las métricas macro de *F1-Score*, *Precision*, *Recall* y *Accuracy* sobre los datos de prueba para los mejores modelos.

7.1. Comparación de Modelos

Los modelos evaluados produjeron los siguientes resultados:

Modelo	Familia	Acc_Train	Acc_Test	F1_Macro	Precision Macro	Recall Macro
modelobase_LR	Lineal	0.8981	0.9043	0.8989	0.9049	0.9009
XGBoost	Ensamble	1.0000	0.9809	0.9794	0.9804	0.9792
svc	Kernel	1.0000	0.9713	0.9696	0.9701	0.9696
lr_Ridge_L2	Lineal	0.9814	0.9713	0.9694	0.9697	0.9693
Lasso_L1	Lineal	0.9850	0.9713	0.9693	0.9701	0.9692
MLP	Red Neuronal	0.9838	0.9569	0.9547	0.9560	0.9544
random-forest	Otro	1.0000	0.9569	0.9539	0.9540	0.9545
Naive_Bayes_Gaussian	Otro	0.6405	0.6268	0.5933	0.6272	0.6159
AdaBoost	Ensamble	0.4943	0.4928	0.4119	0.4766	0.4950

Tabla 3: Comparación detallada de métricas por modelo y familia

Como se observa, el **modelo base (Regresión Logística)** obtuvo un *Accuracy* de 0.90 y *F1 Macro* de 0.899, mientras que **XGBoost** registra un *Accuracy* de 0.98 y *F1 Macro* de 0.979. Los modelos lineales alcanzaron un desempeño superior al 96 %.

7.2. Modelo Seleccionado

El modelo XGBoost presentó el mejor desempeño general y fue seleccionado como modelo final. La matriz de confusión correspondiente se presenta a continuación:




Figura 5: Matriz de confusión del modelo XGBoost

7.3. Sanity Check

Se realizaron 100 iteraciones de entrenamiento y evaluación utilizando particiones aleatorias para validar la estabilidad del modelo. Dado que se trata de un problema de salud pública, el **Accuracy** puede quedarse “corto” y llegar a ser engañoso, por lo que se calcularon otras métricas. El modelo seleccionado demostró un comportamiento consistente logrando un **F1-Score Macro** promedio de 0.9668 ± 0.0088 , lo que confirma su capacidad de generalización equitativa para todos los niveles de obesidad.




Figura 6: Estabilidad del modelo XGBoost

8. Interpretabilidad

8.1. Importancia global de variables (Gradient Boosting)

De acuerdo con el análisis de importancia de variables del modelo, las predicciones están fuertemente influenciadas por una combinación de factores demográficos, físicos y de estilo de vida. A continuación, se presentan las siete características principales:

- **Gender** (37.16 %): es, con amplia diferencia, el factor más determinante para el modelo.
- **Weight** (13.25 %): como indicador físico directo, ocupa el segundo lugar en importancia.
- **type_transportation_Walking** (10.69 %): el desplazamiento a pie destaca como una variable relevante asociada con la actividad física cotidiana.
- **frequently_consump_high_calorie_food** (6.31 %).
- **freq_consump_alcohol** (4.19 %).
- **Height** (4.00 %).
- **consump_food_between_meals** (3.33 %).




Figura 7: Importancia global de variables

8.2. Análisis SHAP

Se utilizaron valores SHAP para explicar las predicciones del modelo, con énfasis en la categoría **Overweight Level I**. El análisis del resto de las categorías se presenta con mayor detalle en el notebook del proyecto.




Figura 8: SHAP Summary Plot

El análisis de la categoría **Overweight Level I** muestra que el modelo identifica un perfil específico en el que las variables físicas dominan la decisión, mientras que los hábitos de vida funcionan como factores de ajuste fino:

- **Peso y estatura (variables dominantes):** el peso presenta un efecto no lineal claro; los valores intermedios activan esta categoría, mientras que los extremos la descartan. La estatura actúa en sentido inverso: a mayor altura, menor es la probabilidad de pertenecer a esta clase, debido a su relación con el IMC.
- **Hábitos alimenticios:** Un **menor consumo de vegetales** aumenta la probabilidad de pertenecer a esta clase. Y un **alto consumo de agua** también es predictivo. El modelo capta esto probablemente como una medida compensatoria (personas que ya están en esta categoría y buscan hidratarse más para seguir una dieta).
- **Género:** La dinámica se invierte respecto a la clase de peso normal; en este conjunto de datos, ser mujer incrementa ligeramente la propensión a ser clasificada en esta categoría.
- **Sedentarismo tecnológico:** Los valores altos en el tiempo de uso de dispositivos electrónicos suman positivamente a la clasificación, confirmando el impacto de los hábitos sedentarios.

Perfiles de las demás categorías

- **Insufficient Weight:** Para esta categoría, la combinación de un peso muy bajo y una estatura alta es el factor determinante, asociándose principalmente a personas jóvenes. Curiosamente, variables como el género o el historial familiar pierden toda relevancia aquí. En cuanto a hábitos, destaca un consumo frecuente de vegetales y de alimentos entre comidas, lo cual el modelo asocia con un metabolismo más acelerado propio de la edad.
- **Normal Weight:** Clasificar en este grupo está fuertemente impulsado por un peso bajo a moderado y una mayor altura, compensando el IMC. A diferencia del peso insuficiente, aquí la ausencia de antecedentes familiares de sobrepeso es crucial. Conductualmente, estas personas reportan una mayor actividad física y la costumbre de comer entre comidas, existiendo una ligera mayor probabilidad de pertenecer a este grupo si se es hombre.
- **Overweight Level II:** El perfil se define por un peso medio-alto combinado con una estatura media-baja y una edad más avanzada. A partir de esta categoría, los antecedentes familiares de sobrepeso se vuelven un factor de peso. Además, destaca un estilo de vida marcadamente sedentario, caracterizado por baja actividad física, uso frecuente de transporte público y dispositivos electrónicos, superando a los factores puramente dietéticos.
- **Obesity Type I:** Un peso elevado se convierte en el motor principal, pero aquí los hábitos alimenticios desplazan a la actividad física como determinantes. Se observa un bajo consumo de vegetales y un paradójico alto consumo de agua, que el modelo capta probablemente como una medida compensatoria de dieta. Además, la tendencia de género se invierte respecto al peso normal, mostrando una mayor propensión en mujeres.

- **Obesity Type II:** Aunque el peso muy elevado sigue dominando, la mayor edad toma el control secundario, haciendo que ser joven disminuya drásticamente la probabilidad de entrar en este grupo. La dinámica de género da un giro completo, asociándose fuertemente a los hombres. Su perfil conductual es muy específico: nula o baja actividad física, combinada con un bajo consumo de agua y de alcohol.
- **Obesity Type III:** En esta categoría extrema, el modelo se simplifica: el peso absoluto es tan alto que variables como la estatura, la edad o los hábitos de sedentarismo pierden casi toda su importancia. El hallazgo más drástico es su abrumadora asociación con el género femenino. Paradójicamente, reportan un alto consumo de vegetales, lo que sugiere que estos pacientes podrían estar bajo regímenes médicos o dietas estrictamente monitoreadas.

9. Conclusiones generales

1. La reconstrucción del IMC (peso y estatura predominan)

El modelo XGBoost logró “deducir” la fórmula del Índice de Masa Corporal (IMC), sin que se le diera la variable explícitamente:

- Para este conjunto de datos, indiscutiblemente el peso es la variable más importante, esto lo vimos desde los descriptivos, ya que es un claro diferenciador entre las categorías. En los extremos (Insufficient Weight y Obesity Type III), domina por completo la predicción de forma polarizada. En las clases intermedias (Overweight Level II), el modelo logra encontrar los “puntos medios” gracias a su naturaleza no lineal.
- La estatura también juega un papel importante en casi todas las categorías. Peso bajo o medio y estatura alta, empuja hacia categorías como Insufficient Weight o Normal Weight, mientras que peso alto y estatura baja o media, empujaría a clasificar a la persona en algún tipo de sobrepeso u obesidad. Únicamente en la categoría de “Obesity Type III” la estatura deja de tener relevancia, aquí el peso extremadamente alto es el protagonista.

2. El comportamiento fluctuante del Género

- En Normal Weight, se inclinaba ligeramente hacia los hombres.
- En Obesity Type I, se inclinó ligeramente hacia las mujeres.
- En Obesity Type II, se asoció fuertemente con los hombres.
- En Obesity Type III, se volvió una regla casi exclusiva para las mujeres.

Esto demuestra que el algoritmo encontró interacciones profundas (probablemente ligadas a características biológicas y demográficas específicas de este conjunto de datos).

3. La Paradoja de los Hábitos (Causalidad Inversa)

El modelo detectó patrones de consumo que a primera vista parecen contraintuitivos, pero que pueden ser un reflejo de la realidad médica observacional:

- Un alto consumo de agua o vegetales apareció fuertemente ligado a categorías como Obesity Type I y Obesity Type III. Esto no indica que tomar agua o comer verduras cause obesidad, sino que refleja un sesgo de tratamiento o compensación: las personas en niveles altos de obesidad suelen estar sometidas a dietas, tratamientos médicos o intentos activos de mejorar su salud, reportando consumos altos de estos alimentos “sanos”.
- Por otro lado, comer frecuentemente entre comidas se asoció más con Normal Weight e Insufficient Weight, desmintiendo la idea general de que “picoteos” simples causan aumento de peso sin contexto de las porciones o metabolismo.

4. La Edad y el Historial Familiar

- Ser más joven empuja hacia el peso normal o insuficiente, mientras que la edad media y avanzada son cruciales para clasificar en sobrepeso u obesidad tipo II. Sin embargo, en los extremos absolutos (Obesity Type III), la edad deja de importar.

- El Historial Familiar es la barrera de entrada al sobrepeso. No tenerlo es el principal escudo protector para mantenerse en Normal Weight, pero una vez que el paciente cruza hacia la obesidad, las variables físicas y los hábitos toman el relevo.

5. Actividad física y uso de dispositivos electrónicos

El sedentarismo se refleja ya sea en la poca o nula actividad física y/o en el tiempo que se pasa frente a dispositivos electrónicos. Aunque estas variables no aparecen en el top, sí tienen un comportamiento claro en Overweight Level II, Obesity Type I y II.

La ayuda de un especialista en este campo nos permitiría confirmar o rechazar y dar una mejor interpretación de los resultados.

Referencias

- [1] Vandenbroeck, P., Goossens, J., & Clemens, M. (2007). *Tackling Obesities: Future Choices – Obesity System Atlas*. Government Office for Science. Disponible en: <https://assets.publishing.service.gov.uk/media/5a7b8811ed915d4147620fb2/07-1177-obesity-system-atlas.pdf>
- [2] Palechor, F. M., & De La Hoz Manotas, A. (2019). *Estimation of Obesity Levels Based on Eating Habits and Physical Condition* [Conjunto de datos]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5H31Z>
- [3] De La Hoz-Correa, E., Mendoza-Palechor, F., De-La-Hoz-Manotas, A., & Morales-Ortega, R. (2019). “Obesity Level Estimation Software Based on Decision Trees”. *Journal of Computer Science*, 15(1), 67–77. <https://doi.org/10.3844/jcssp.2019.67.77>
- [4] Organización Mundial de la Salud. (2024). *Obesidad y sobrepeso*. Recuperado de: <https://www.who.int/es/news-room/fact-sheets/detail/obesity-and-overweight>